

文件图像分析系统概述

安德烈·提戈拉¹

抽象

本白皮书概述了文档图像分析系统及其组成模块，这些模块使用的方法以及这些应用的用途。之一主要目标是提出一些最重要的技术和方法文档图像分析域，以评估处理时的最佳方法与真实世界的文件。另一个主要目标是确保为那些开始的基础建立这样复杂的软件系统并给出一个详尽的技术答案问题：“如何为大量人员提供物理文件？”

关键词：文档图像分析，字符识别，OCR，图像数据提取，图像导出

1.引言

扫描物理页面并以数字格式存储它们是制作物理页面的一种手段数据可用于数字世界。它也解决了存储，纸张的问题恶化，无障碍等等。然而，它没有做的是让它更快查明与某项工作相关的数据；给像素结构和将基础信息提取到计算机可理解的表示中文档图像分析（DIA）系统的工作。在谈论DIA系统时，第一个想到的东西是光学字符识别[2] [16]，都是因为它在美国邮政系统中使用相当长一段时间，因为它是用户的东西甚至在与非文本文件进行交互时也会期待。但是，OCR不在了而不是大型应用程序的一小部分，并且代表狭义的内容DIA真的是。

文档图像分析通常针对合成图像[1]，包含的图像符号对象，例如书页，字母上的邮政地址，工程图纸，乐谱，地图等。但是，它也可以处理自然发生的模式好，如指纹分析[16]。另一类图像由表示“自然”图像，如照片，卫星图像，X射线 – 可能的物体用标准或非标准相机拍摄。中国交通标志的图片可能是这两个类别的一部分，取决于它的预期，但这不应该代表一个其余讨论的问题。

2.处理步骤

首先应该指出的是，没有这样的东西作为一个独特的公认的分类处理步骤图像从原始形式经历到计算机可理解数据。Nagy [1]提出了一个综合性的分类标准，并对程序进行了分类

¹ 工程师，Jinny Software Romania SRL 13 C Pictor Ion Negulici, 罗马尼亚布加勒斯特, andrei.tigora@jinnysoftware.com

第2页

基于他们处理的实体的粒度。五个确定的级别，开始从最低粒度开始，如下所示：

- 像素级别
- 原始级别
- 结构级别
- 文档级别
- 语料库级别

纳吉的分类标准还区分了输入图像的性质，即分离那些内容大部分是文本的，大部分是由非文本图形组成的。字符和图形主导图像之间的类似差异也被反映出来在[2]中。但是，对于某些输入图像，取决于所需的输出，处理步骤来自这两个类别可能是必要的。例如，电路图的扫描图像将需要OCR处理和专用线路检测以及电路识别零件。

本文中使用的分类松散地基于Nagy的分类[1]。该下一节将介绍每个级别的概述，重点介绍文本文档。

3.像素级处理

像素级处理处理图像到图像，试图变换给定的图像进入更适合以下级别的版本。属于这个的算法分类处理降噪，二值化，字符分割，字符缩放和矢量。

降噪

图像中的噪点有多种原因，例如输入图像质量下降，拍摄不完美设备，以及不正当使用以前使用的设备，压缩和传输错误。在使用图像之前，光学异常必须是补偿。

降噪旨在提高信噪比，而不仅仅是为了降低噪音图像，但对于所有形式的信号。在数字处理领域，它发挥着重要的作用角色不仅在数字图像分析中，而且在医学[20]和天文学[23]中也是如此。噪声可以应用于双色调[16]，灰度[21][22]，以及直接对色彩图像[19][20]。大多数降噪机制都会对噪声做出假设分布模式[18]。由于其简单性，高斯分布被广泛假定[19][5]，但也考虑了泊松分布[20]以及非高斯分布分布[5]。

现在用于降噪的方法非常多样化[5]以及更多比十年前使用的那些复杂[2]。经典的方法是形态学方法，它依赖于侵蚀和膨胀变换的顺序结合分割启发式[63]。这些是非线性滤波器，并与其一起使用线性滤波器，如基于高斯滤波器[17]的滤波器，属于空间域滤波

第3页

类别。最近，特别关注变换域滤波；其中，最好的结果似乎是由小波域滤波器产生的[21]。虽然它们比自然图像的其他方法表现更好，但它们看起来并不像成功地使用了合成文件，它们代表了文件图像分析的重点系统。

二值化

就像降噪一样，二值化[64]与多种类型的图像相关，不仅如此用于文档图像。通过二值化过程，图像的像素是分配给两个类别：前景和背景。这也许是最激进的由于重大的信息损失，图像经历了变换；然而，对于一个文本图像，这种简化不应该使图像像字符一样失去任何价值将成为前景和图像背景的其余部分。

最常用的算法是基于阈值的[24] [25] [26]；阈值方法计算一个全局或本地值（阈值）[64] [65]，它使用黑色之间的分隔符和白色像素。二值化和降噪可以在一个步骤中结合在一起以更好地分类什么是前景和什么是背景。[62] [63]一个不同的方法用于抖动算法：半色调[27]和有序[28]。这些试图仅使用预定义重现给定边界内的颜色密度一组颜色值。最后一种二值化算法是误差分散技术[29]；他们的目标是尽量减少图像中的错误表示近似和传播相邻像素之间的色差。

歪斜校正

倾斜检测而非纠偏本身是所使用的各种算法的主要焦点进行偏斜校正。图像歪斜是不正确处理文档的结果数字化过程；取决于设备和文档的性质，不正确放置可能导致文档边界周围出现黑暗区域，称为边际噪声[8]。尽管纠错不关心删除边际噪音，这两种增强通常是一个接一个地进行的。一个正确对齐的文档简化了字符和文本行检测算法[7]，假定文本本身具有预期的有序分布。

偏斜估计的一些方法依赖于投影轮廓或Radon变换。这些算法在一定限度内旋转图像并评估获得的投影型材；变异最大的一个对应于倾斜角[5] [66]。就像投影轮廓，霍夫变换方法执行可能的角度值的扫描试图确定图像歪斜；他们依赖最多线的观察像素将沿着平行于文本行的基线[4] [7] [31]的线遇到。霍夫空间中的过滤可以提高结果[69]，但不幸的是这些都没有方法在处理也包含图像的文档时产生良好结果，如他们有不同的像素分布影响统计。

与以前的方法不同，最近邻方法首先确定字符块然后通过最近的那些进行分组。这是在他们假设下完成的

必须是同一文本行的一部分。一旦确定了邻居组，斜交角通过分析相邻实体之间的变化来计算[5] [30] [67]。这些方法也有一个缺点：它们对噪声非常敏感，可能会引入噪声扰乱邻里创造过程的人造实体。然而，有

筑面检测到的旋转畸变图[6]并且甚至可以校正弯曲的方法

字符分割

字符分割涉及识别图像中的特定区域对应于单个字符。高质量地分割基于拉丁文字的印刷文本图像几乎没有问题，因为很少 – 最多3个，但通常只有一个 – 连接组成角色的组件。这通常通过确定连接来解决组件并运行最近邻居算法来为其分配各种变音符号相应的中央实体。

但是，对于低质量的图像，字符倾向于合并或分裂为多个实体，一些字体比其他字体更容易出现某种行为。这种情况对于其他脚本是常见的，例如阿拉伯语，字符链接或汉语[56]，其中字符可能由几个不同的组件或脚本组成人们知道如何解读，就像兰纳那样具有感人和重叠的字母。[14]因此，最初设计的一些机制解决了低质量问题图像实际上用于这些特定脚本的字符分割。

分离合并的字符可以通过明确的字符识别完成[32] [33] [35]。然而，这限制了对特定脚本的分割，使其不那么通用。另一种解决方案依赖于垂直投影[33] [34]，其目的是确定以最少的像素进行坐标并沿该坐标分割。细化[33] [34]也可能因为它可能导致合并点的“自然”消除，但它可以同样过分地分割现有的角色。

将分离的实体合并为单个字符通常归结为评估各种组件之间的距离。这些组件可以用它们来表示边界框或像素本身或通过Voronoi图，Delaunay三角测量或3D网格。[70] [71] [72]

4.本体级加工

原始级处理的目的是确定元素的性质在预处理步骤之后变得可访问。而文本文件则是重点是对角色的最终认可，对于目标所认识的非文本文档基本的几何实体。[13]对于扫描地图，文本元素的扣除变为更难，因为文本有各种不同的方向，并放置在可变的彩色背景上。形态学操作与统计数据一起帮助识别有趣的区域。[15]

第5页

字符识别

早期的字符识别工作是在拉丁文字上进行的，因为它是主要的西方世界的脚本。虽然还不完美，但在理想情况下，角色识别率接近100%[36]。所有方法在某种程度上都依赖于匹配a候选人角色反对一组功能。最基本的方法是使用参考然后将该字符的位图与候选的缩放版本进行比较。更多可靠的参考集由线条笔划，笔划交叉，相对角度[1] [37]组成。该目的是发现一些可以唯一且明确地将某些特征分类的特征候选对象恰好属于一个组。参考设置的功能是通过机器学习确定，通常是一个神经网络。

字符分类传统上以每个字符为基础进行确定其特征最适合拟议的角色。适应度函数通常是相对的。简单地说，就距离而言，计算候选人与参考模式的偏差从参考的功能列表。然而，多年来的经验表明这种方法具有高度的模糊性，这只能通过使用更高的解决方案来解决级别的信息，如语言模式。通过考虑语言信息，使用广义隐马尔可夫分类可以变得更加精确模型或贝叶斯网络，从而表明更可能的字符序列发生。

在某种程度上可以说，这个领域已经成熟了，与开发者和研究人员同样承认目前OCR产品的性能[11] [36] [41]。

目前关于字符识别的研究大多针对阿拉伯语和中文脚本以及手写文档[2]。基于手写和阿拉伯文脚本的文本在两种情况下，形成单词的字符彼此相关。也，而阿拉伯字符的形状因上下文而异，字符的形状为手写文本往往会显示更大的变化，不仅在写文档之间不同的人，但也在同一个文件。

对于基于中国的剧本，以及其他受其启发的剧本，主要难点在于大量的可用字符，这使得它们不适合用于评估用于拉丁文脚本的方法。然而，有一些机制可以回应以及该脚本强加的要求，如Tesseract [37]。总体而言，大部分为分析拉丁文字而开发的算法可以适用，但次要修改/定制任何类型的脚本[39] [40]。

5. 结构层面处理

对于这一级别的处理，目标是给诸如“实体”这样的实体组赋予“含义”识别单词，重构文本行和解释表格。[10]

分词问题必须再次接受不同的处理在使用的脚本上。现代拉丁语剧本使用空格作为分隔单词的手段

第6页

并在一些特殊情况下使用其他符号，如连字符。原始拉丁纪念碑题词虽然，并没有分开的话；这同样适用于中文。

对于基于拉丁文字的文本，分隔单词是评估两者之间距离的问题连续的字符。然而，对于嘈杂的文档图像，字符之间的距离会受到意想不到的暗像素的影响，因此需要分割单词某种语言模型信息。这对于中文文本也适用不使用任何形式的分隔符，并依靠读者的知识来决定分裂的位置的话。

使用语言信息意味着分割成为OCR类型的处理。最古老的方法可以追溯到20世纪60年代，当时N-grams被认为是错误的校正[1]，后来扩展到分词[55]，作为高位的替代使用完整词典的要求[57]。N-gram和字典都可能是从已有的知识库中获得[55]，或从“相关”分割产生来源[57]。实际的分割评估候选序列，选择那个

具有最高的概率，因为它们通常长得很宽。语言信息可以在上面生成从扫描的文档中找到，然后用于进一步的分割文件或后期处理中的更正。 [74]

6. 文档级处理

现代文档级处理集中在文档布局分析上，这是将元素分组为逻辑顺序，并在一定程度上识别出优秀的文本的元素，例如作者，标题等。对于布局分析，假定这是诸如单词（甚至文本行），表格和图像等实体已被识别，连同他们的包围盒。有关内容的性质的信息边框不是强制性的。分组不同的元素是一个观察问题在撰写文本时通常会遵守的距离惯例，寻找解释空格，行[75]和任何表单分隔符[76]。检测字体的方法特征准确地提供有价值的信息[70]。作者评估这些距离相对于文本大小[77]，因为分隔两个文本列的空白列需要很大足以明确分割具有相同垂直坐标的两条线[42]。对于自顶向下的方法，所谓的XY切割算法被采用，基于XY树，通过两个轴中的一个递归地分割/剪切图像中的区域，最终结束 a [45]

如前所述，布局分析并不局限于分组元素；它也是执行文字标签。这可以通过自下而上和自上而下来实现方法。标签可以完全依赖块页面分发[44]，或者是增强了OCR信息[45]。

其他重要问题是检测表格，图表，图片和文本区域的问题一个文件图像。算法应该能够从图像中切出每个元素不包括其他物体的零件，即使这意味着以不规则的方式切割 [78] [71]。

第7页

检测表格区域的一种方法是识别组成的图形元素该表格：线段和交点[58]。这往往是相对有弹性的噪音，但它不能应用于没有图形组件的表格。其他解决方案尝试分析某个地区内的单词分布并基于此做出决定他们的立场相对于其他的话。

在[59]中，作者试图根据行线稀疏来确定表格，这是多大特定行上的空格是。但是，这假定表格单元格很少内容，这可能并非总是如此。基于对齐的方法被提出在[60]首先识别窄文本列，然后将它们组合成表格。一个混合实现在[61]中描述；这试图结合非表格诸如标题和预告位置的信息，将空格单元格分隔为的空格/行以及背景颜色的变化。

7. CORPUS LEVEL 处理

一旦文件图像被完整的分析和信息增强，互动，这些互动可能适用于扫描的应用程序特定数字版本文件应该可供用户使用。这些包括内容索引和搜索，以及验证和文档更新。在编目论文时，人类首先应对名称，例如出版物的标题，所以期望机器会这样做一样的东西。不幸的是，真正需要自动索引的文档是

通常导致了真值误差，例如OCR性能不佳[96]。因此，算法首先在一组图像上训练以学习现有的布局，然后进行分类阶段，为每个新图像确定布局[71]，并且健身评分为根据图像中的多边形与参考上的多边形的匹配程度来计算[43] [46]。这种布局识别方法也可以用作检索机制可以证明是比OCR更强大的机制。

然而，信息提取机制可以依赖像素这样的低层次元素。[47]的作者描述了一种使用像素分布的图像识别算法测量来识别特定的图像。稍高一点的方法分析字符形状，更精确地说是字符的垂直段，以构建图像功能集，然后用于识别一个特定的文件[9]。

8. 绩效评估

评估特定算法的性能不应成为争议的问题，然而，在文档图像分析领域它通常是。第一个问题来自于模块化，文档分析系统的分层结构。在这方面，a 二值化算法不能简单地通过将其输出与地面进行比较来进行评估真理形象。图像清晰度指标是一个有用的起点[73]；更可靠指标将是正确识别人物和其他特征的较高者级分析仪。即便如此，一个先进的OCR分析仪实际上可能会隐藏一个平均值性能较低，所以应该使用替代方法进行比较模块。

第8页

选择参考图像也是一个重要组成部分。虽然有一个一般的一致认为使用大量的文件是可取的[1]，当社区分裂时，社区就会分裂涉及到那些应该使用的文件。这个问题存在于二值化中达到高级处理算法的方式。参考输出，即所谓的“地面真相”是最大的问题。例如，当对艺术图像进行二值化时，照片是非常不可能有一个独特的令人满意的二进制图像，而对于合成图像，二进制参考通常是唯一的 - 除非图像中的噪声是由于某种原因更相关的实际内容。尽管它的独特性，另一个产生地面真实信息的问题出现了。一方面，可能会开始从实际出发并以各种方式扭曲它，以便处理的输入是原始基础事实的扭曲版本。替代方法是生成来自通常由程序或平台处理的文档的基本事实。如预计，这两种方法都有其缺点；第一个是相对较快并允许的设计师可以很好地控制他们期望测试的扭曲类型，但扭曲图像往往是“不自然的”。因此，针对这些评估的算法对于真实文档中从未遇到的情况，输入信息正在进行微调。该另一方面，后者的解决方案虽然提供了切合实际的输入，但没有快速手段迅速产生地面真相 - 地面真相必须由手工产生使得这种方法对于当前的测试需求是不可扩展的[38]。

9. 分析系统方法

理想情况下，一个软件包应该能够从任何类型中提取信息它提供的文件，但事实是，大多数时候高度专业化的软件是用于解决特定的问题。为了获得最佳结果，分析系统以及他们的组件，往往具有有限的适用性。这可能涉及有限的一系列处理比可以执行的处理，对文档的质量施加限制，有限的语言支持，这意味着只有使用特定语言编写的文档

可能被处理，或者是特定的文档布局，用于归档其格式的文件
 一篇文被编地重复[12][48]。然而，即使输入材料受限于
 对内容的观点来看，所需的处理可能会非常复杂，因为处理得很高
 各种其他参数，如纸张颜色，非标准文本布局和广泛的范围
 手写风格是[53]的情况。

文档图像分析系统可能在范围上受限于诸如提取等
 文件名[4]，或仅处理表格，图形和图像[3]。这是
 简化依赖于只有某些信息值得使用的假设
 文件索引。

文献[6]中描述的系统完全避开了字符识别，提取“单词”
 图像“，然后通过逐字匹配用户输入的关键字
 匹配。

有些系统根本无法弥补文件的低质量
 处理，所以设计人员开发了依赖于用户反馈的系统。如[36]所述，
 没有人为干预，结果往往会显着降低，因此人为干预
 对于良好的结果是强制性的。在[7][12]中提出的系统使用最初的人类输入
 创建之后用于提取类似构造的信息的模板

第9页

文档，而不需要其他用户干预。更常见的是，允许
 人类用户检查分析的建议结果并相应地进行修正
 [12][51]。

其他系统允许用户完全控制自己的能力[49]，这可能是
 每当批处理模式处理不会产生预期结果时都很有用。更多
 激进的做法是将整个文件分析留给最终用户[50]
 一个大型的科学家社区的优势，这些科学家对这些文档感兴趣并且能够
 合作加强它们。一定程度的自动化处理可以被整合
 尽管如此，已经在[51]中尝试过了。但是，为了消除努力
 应该使用单一共享的文件模型[52]。人群采购
 也用于[54]，以便检查自动化处理的结果并加以改进
 最终文件的质量。

10. 结论

由于输入材料种类繁多，所有问题都没有通用的解决方案。

但是，为特定文档输入类别和特定文档找到最佳解决方案
 （预）处理阶段是可能的。为了充分利用“最佳”解决方案
 合适的“处理环境/阶段一个智能文档图像分析系统
 这将允许选择算法/方法来解决特定问题
 以及最适合该任务的参数设置。

11. 参考文献

1. G. Nagy, “20年的PAMI中的文档图像分析”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 卷。第22号, 第1号, 2000年1月。
2. R. Kasturi, L. O'gorman, V. Govindaraju, “Document image analysis: A primer”, *Sadhana*, Vol. 第27号, 第1号, 2002年2月。
3. X. Lu, S. Kataria, WJ Brouwer, JZ Wang, P. Mitra, C. Lee Giles, “Automated analysis of document images”, *国际期刊文件分析与识别*, 卷。第12号, 第2号, 2009年6月。
4. L. Likforman-Sulem, P. Vaillant, AB de laJacopièrre, “Automatic name extraction from degraded document images”, *模式分析和应用*, 卷。第9号, 2-3号, 10月

- 2006年。
5. T. Saba, G. Sulong, A. Rehman, “文档图像分析: 问题, 方法比较和剩下的问题”, *Artificial Intelligent Review*, Vol. 35, No. 2, 2011年2月。
 6. CB Jeong, SH Kim, “用于关键词识别的文档图像预处理系统”, *第七届数字图书馆国际会议论文集: 国际合作和交叉受精*, 2004年12月。
 7. C. Antonio Peanho, H. Stagni, FSC da Silva, “语义信息抽取复杂文件的图像”, *Applied Intelligence*, Vol. 2012年12月号第37号, 第4号。
 8. Z. Hu, X. Lin, H. Yan, “基于多密度特征的文档图像检索”, *中国电子与电气工程前沿*, Vol. 2, 2007年第2期。
 9. 陈, W. Huang, SY Sung, Z. Yu, Y. Xu, “从文档图像中检索文本基于Word形状分析”, *Applied Intelligence*, Vol. 18, 第3号, 2003年5月至6月。

第10页

10. J.-Y. Ramel, S. Busson, ML Demonet, “AGORA: 交互式文档图像BVH项目的分析工具”, *第二届国际文档图像会议2006年图书馆分析2006年4月27 - 28日*。
11. A. Antonacopoulos, D. Karatzas, “第二次世界大战个人档案图像分析”记录”, *第一届国际文献图像分析研讨会论文集图书馆*, 2004年。
12. J. He, AC Downton, “用于数字图书馆的用户辅助归档文档图像分析建设”, *第七届国际文件分析和会议论文集确认*, 2003年8月3日至6日。
13. EE Regentova, S. Latifi, D. Chen, K. Taghva, D. Yao, “通过处理分析文档JBIG编码图像”, *国际文件分析和识别杂志*, Vol. 7, 第4号, 2005年9月。
14. S. Pravesjit, A. Thammano, “历史兰纳手抄本的分割”, *智能系统 (IS)*, 2012年第6届IEEE国际会议, 2012年9月6 - 8日。
15. S. Biswas, AK Das, “从扫描的土地图像中提取文本”, *2012年国际版信息学, 电子与视觉会议 (ICIEV)*, 2012年5月18 - 19日。
16. LO Gorman, R. Kasturi, “文档图像分析”, *Los Alamitos: IEEE CS Press*, 1995年。
17. J. Lee, R.-H. Park, S.Chang, “使用多尺度双边分解进行噪声降低数字彩色图像”, *信号, 图像和视频处理*, 2012年8月。
18. H.-Y. Lim, D.-S. 康, “使用定向修改的图像高效降噪西格玛过滤器”, *超级计算杂志*, 2012年12月。
19. J. Harikiran, R. Usha Rani, “用于高斯噪声的彩色图像恢复方法去除”, *计算机信息和通信技术通信和Information Science*, Vol. 101, 2010, pp 554-560。
20. S. Okawa, Y. Endo, Y. Hoshi, Y. Yamada, “减少测量时间的泊松噪声 - 解决时间域漫反射光学层析成像数据”, *医疗与生物工程与计算*, 50 (1), 2012, pp 69-78。
21. ADE Stefano, PR White, WB Collis, “图像阈值选择方案的选择”*Noiselet on Wavelet*, 2004, 第225-233页。
22. M. Nachttegael, S. Schulte, D. Weken, D. Van Der, V. De Witte, EE Kerre, “Do Fuzzy技术为图像降噪提供附加价值?” *高级概念智能视觉系统*, 2005年, 第658-665页。
23. S. Harmeling, B. Scholkopf, HC Burger, “从天文图像中消除噪音使用像素特定噪声模型”, *IEEE国际计算会议摄影*, 2011, 第1-8页。
24. N.Otsu, “灰度直方图的阈值选择方法”, *IEEE Transactions 系统, 人与控制论*, 1979。
25. M. Sezgin, B. Sankur, “调查图像阈值技术和定量性能评估”, *电子成像杂志*, 2004年。
26. J. Zhang, J. Hu, “基于二维Otsu方法和直方图分析的图像分割”, *国际计算机科学和软件会议论文集*

27. AR Ulichney, “频域中的半色调表征”, *影像科学和科技第47届年会*, 1994年。
28. AR Ulichney, “用于抖动阵列生成的空白和聚类方法”, *SPIE*, 1913年, 1993年。
29. RW Floyd, L. Steinberg, “自适应算法的空间灰度”, *Proceedings of 2004 信息显示学会*, Vol. 17, pp.75–77,1976。

第11页

30. Y.Lu, CLTan, “基于最近邻链的偏差估计方法文件图像”, *模式识别字母*, 卷. 24, pp.2315–2323,2003。
31. YM Alginahi, “关于阿拉伯字符分割的调查”, *国际期刊文件分析和承认*, 2012年。
32. J. Wang, J. Jean, “用神经网络和最短路径分割合并字符”路径“, *Proceedings of the 1993 ACM / SIGAPP symposium on Applied computing*, 769-772, 1993。
33. YM Alginahi, “关于阿拉伯字符分割的调查”, *国际期刊文件分析和承认*, 2012年。
34. A. Zahour, B. Taconet, L. Likforman–Sulem, W. Boussellaa, “Overlapping and multi-通过块覆盖分析来触摸文本行分割“, *模式分析和应用程序*, 2008。
35. A. Nomura, K. Michishita, S. Uchida, M. Suzuki, “检测和分割在数学表达中接触人物“, *第七届国际会议文件分析与识别*, 第126–130页, 2003。
36. 霍利, R. “它有多好? 分析和提高大规模OCR精度历史报纸数字化计划“, *D-Lib Magazine*, Vol. 15, 第3期, 第1–13页, 2009年。
37. R. Smith, “Tesseract OCR Engine概述”, *第九届国际会议关于文件分析和识别*, 第2卷, 第629–633页, 2007。
38. J. Callan, P. Kantor, D. Grossman, “信息检索和OCR: 来自转换内容抓住意义“, *ACM SIGIR Forum*, Vol. 2002年第36卷第2期, 第58–61页。
39. F. Hedayati, J. Chong, K. Keutzer, “用西藏木刻印刷品的认识”广义隐马尔可夫和核化修正二次距离函数“, *关于噪声的多语言OCR和分析2011年联合研讨会会议论文集非结构化文本数据*, 2011年。
40. MK Jindal, M. Kumar, M., RK Sharma, “脱机手写Gurmukhi字符识别: 不同特征 – 分类器组合研究“, *论文集文件分析和识别页面研讨会*, 第94–99页, 2012。
41. H. Déjean, J. Meunier, “根据目录建立文件“, *ACM关于文档工程的讨论会*, 2005年2月9日。
42. PE Mitchell, H. Yan, “采用连接线的报纸文件分析”细分“, *Pan–Sydney区域视觉信息研讨会论文集处理*, 卷. 11, pp.77–81,2001。
43. L. Golebiowski, “Automated Layout Recognition”, *第一届ACM硬拷贝研讨会文件处理*, 第41–45页, 2004年。
44. 罗森菲尔德, R. 费尔德曼, Y. 奥曼, “从视觉布局提取结构文件“, *第十一届国际信息和通信会议论文集知识管理*, 第203–210页, 2002年。
45. A. Takasu, K. Aihara, “从随机扫描文件中提取信息”页面布局分析“, *2008年ACM应用计算研讨会论文集*, 第447页, 2008年。
46. L. Lecerf, D. Maupertuis, “基于布局的文档检索和可扩展索引”排名“, *2010年ACM应用计算研讨会论文集*, 第28–32页, 2010。
47. Z. Hu, X. Lin, H. Yan, “基于多密度特征的文档图像检索“, *中国电子与电气工程前沿*, Vol. 2, 2007年第2期。
48. ABS Almeida, RD Lins, GDF Pereira e Silva, Thanatos: “自动检索

历史文献图像处理”；第146-153页，2011年。

第12页

49. RD Lins, GDF Pereira e Silva, ADA Formiga, “加强处理平台历史文献”，*2011年历史文献研讨会论文集 成像和处理*, 卷。0, pp.169–176。
- P. P. Tranouez, S. Nicolas, V. Dovgalecs, A. Burnett, L. Heutte, Y. Liang, R. Guest, R., “DocExplore: 克服文化和物理障碍获取古代文件”，*2012年ACM关于文档工程的讨论会议录*, 第205–208页, 2012。
51. AH Toselli, E. Vidal, A. Juan, “交互式布局分析和转录系统”为历史手写文件分类和主题描述”，*Proceedings of 第10届ACM文件工程研讨会*, 第219–222页, 2010。
52. R. Sanderson, B. Albritton, R. Schwemmer, H. Van De Sompel, “SharedCanvas: A 中世纪手稿布局传播的协作模型”，*Proceedings of the 第11届国际ACM / IEEE数字图书馆联合会议*, 第175–184页, 2011。
53. E. Matthaïou, E. Kavallieratou, “患者历史信息提取系统文件”，*第27届ACM年度应用计算研讨会论文集*, 787, 2012。
54. T. Ishihara, T. Intoko, D. Sato, A. Tzadok, H. Takagi, “Transforming Japanese Archives into 无障碍数字图书分类和主题描述”，*第12届论文集 ACM / IEEE-CS数字图书馆联合会议*, 2012年第91–100页。
- V. Zhikov, H. Takamura, “一种有效的无监督词分割算法与分支熵和MDL”，*2010年会议实证会议记录 自然语言处理中的方法*, 第832–842页, 2010。
56. A. Chen, “使用最小语言知识的中文分词”，*对中国语言处理第二SIGHAN研讨会论文集*, 第148–151, 2003。
- P. P. Simon, S. Hsieh, L. Prevot, C.–R. 黄, “重新思考中文分词: Tokenization, Character Classification, or Word Break Identification”，*Proceedings of ACL 互动海报和示范会第45届年会*, 69–72, 2007。
58. LA Pereira Neves, JM de Carvalho, F. Bortolozzi, “用表格形式提取 Artefact Removal”，*2007 ACM Symposium on Applied Computing会议论文集*, 622–626, 2007。
59. Y. Liu, P. Mitra, CL Giles, “通过稀疏识别数字文档中的表格边界”在线检测”，*第17届ACM信息和知识会议论文集 采矿*, 第1311页, 2008年。
60. F. Shafait, R. Smith, “异构文档中的表格检测”，*第八届会议记录 IAPR国际文件分析系统研讨会*, 第65–72页, 2010年。
61. G. Harit, P. Art, “使用标题和预告模式的文件图像中的表格检测”，*第八届印度计算机视觉, 图形和图像会议论文集 处理*, 2012年。
62. CA Boiangiu, AI Dvornic. “现代和现代的双色图像转换方法” Classic Documents”，*WSEAS Transactions on Computers*, 第7期, 第7卷, 第1081页 – 1090, 2008年7月。
63. CA Boiangiu, AI Dvornic, DC Cananau, “二值化数字化项目使用 Hybrid Foreground–Reconstruction”，*Proceedings of the 2009 IEEE 5th International 智能计算机通信与处理会议*, 克卢日纳波卡, 8月 27–29, pp.141–144。
64. CA Boiangiu, A. Olteanu, AV Stefanescu, D. Rosner, N. Tapus, M. Andreica, “本地 Thresholding Algorithm Based on Variable Window Size Statistics”，*Proceedings CSCS–18日*, 第18届国际控制系统和计算机科学会议, 5月 2011年24月27日, 罗马尼亚布加勒斯特, 第2卷, 647–652。

第13页

65. CA Boiangiu, A. Olteanu, AV Stefanescu, D. Rosner, Al Egner, “Local Thresholding 图像二值化使用变量窗口标准偏差响应”, *Annals of DAAAM for 2010*, 第21届国际DAAAM研讨会论文集, 20–23 2010年10月, 克罗地亚扎达尔, 第133–134页。
66. B. Raducanu, CA Boiangiu, A. Olteanu, A.Stefănescu, F. Pop, I. Bucur, “倾斜检测 使用Radon变换”, *Proceedings CSCS-18*, 第18届国际会议 控制系统与计算机科学“, 2011年5月24 – 27日, 罗马尼亚布加勒斯特, 卷 2, Pp. 653–657。
67. D. Rosner, CA Boiangiu, A.Stefănescu, N.Tăpus, A. Olteanu, “Text Line Processing for 图像文件中的高置信度歪斜检测“, *ICCP 2010 Proceedings*, Cluj– Napoca, Romania, August 26–28 2010, pp. 129–132.
68. CA Boiangiu, D. Rosner, A. Olteanu, AV Stefanescu, ADB Moldoveanu, “Confidence Measure for Skew Detection in Photographed Documents”, *Annals of DAAAM, Proceedings of the 21st International DAAAM Symposium*, 20–23 October 2010, Zadar, Croatia, pp. 129–130.
69. CA Boiangiu, B. Raducanu, “Effects of Data Filtering Techniques in Line Detection”, *Annals of DAAAM for 2008, Proceedings of the 19th International DAAAM Symposium*, pp. 0125–0126.
70. CA Boiangiu, AC Spataru, Al Dvornic, DC Cananau, “Automatic Text Clustering and Classification Based on Font Geometrical Characteristics”, *Proceedings of the 9th WSEAS国际自动化与信息会议*, WSEAS出版社, 第468页 – 473, 2008年6月24 – 26日, 罗马尼亚布加勒斯特。
71. CA Boiangiu, DC Cananau, B. Raducanu, I. Bucur, “分层聚类方法 针对文档布局理解和分析“, *国际期刊 应用科学中的数学模型和方法*, 第1卷, 2008年第2卷, Pp. 413–423 422。
72. CA Boiangiu, B. Raducanu, “用于图像页面的3D网格简化技术 Clusters Detection“, *WSEAS Transactions on Information Science, Applications*, Issue 第5卷, 第1200–1209页, 2008年7月。
73. CA Boiangiu, AV Stefanescu, D. Rosner, A. Olteanu, A. Morar, “自动倾斜 大规模数字化项目中的边缘目标验证“, *Proceedings of the 21st 21st 国际DAAAM研讨会*, 2010年10月20 – 23日, 第131–132页。
74. CA Boiangiu, DC Cananau, S.Petrescu, A.Moldoveanu, “基于OCR后处理 关于字符模式匹配“, 第20届DAAAM世界研讨会, 奥地利141–144页 维也纳中心 (ACV), 2009年11月25 – 28日。
75. CA Boiangiu, B. Raducanu, “自动内容的线路检测技术” 转换系统“, *WSEAS信息科学交易, 应用*, 第7期, 第5卷, 第1200–1209页, 2008年7月。
76. CA Boiangiu, DC Cananau, AC Spataru, “检测任意形式的分隔符 基于Filtered Delaunay Triangulation“, 第9届WSEAS国际会议论文集 自动化与信息会议, WSEAS出版社, 第442–445页, 布加勒斯特, 罗马尼亚, 2008年6月24日至26日。
77. CA Boiangiu, DC Cananau, Al Dvornic, “基于白色空间探测技术 关于邻里距离测量“, 2008年DAAAM年报, 会议记录 第19届国际DAAAM研讨会, 第131–132页。
78. CA Boiangiu, M. Zaharescu, I. Bucur, “为图像建立非重叠多边形 Document Layout Analysis Results“, *The Journal of Journal ISOM*, Vol. 6第2号/ 2012年12月, 第428–436页。